Assignment 3: BDM

Siddhi Kate

Student_No.: 2982006

Python code: for creating log files.

```
In [1]: import csv
           with open('Day-1.txt', "w") as my_output_file:
    with open('2019-03-01.csv', "r") as my_input_file:
        [ my_output_file.write(",".join(row)+'\n') for row in csv.reader(my_input_file)]
                my output file.close()
  In [3]: import csv
           with open('Day-2.txt', "w") as my_output_file:
    with open('2019-03-02.csv', "r") as my_input_file:
        [ my_output_file.write(", ".join(row)+'\n') for row in csv.reader(my_input_file)]
                my_output_file.close()
import time
a = 1
with open('Day-1.txt', 'r') as file_1:
    with open('Day-2.txt', 'r') as file_2:
           lines_1 = file_1.readlines()
           len_1 = len(lines_1)
           lines 2 = file 2.readlines()
           len_2 = len(lines_2)
           i_{file1} = 1
           j file1 = 1000
           i_file2 = 1
j_file2 = 1000
     while j_file1 != len_1 and j_file2 != len_2 :
           if i_file1==1 and i_file2==1:
                  i_file1 = j_file1
j_file1 += 1000
                  print('creating file log{}.txt'.format(a))
                  a += 1
```

Key space generation:

Streaming application for queries and their output in Cassandra.

1. Question: 1 To calculate the number of downloads of each package.

Output:

```
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                     GeneralizedHyperbolic
                                                            HMM
                                                        HMMCont
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                          нммра
2019-05-02 20:07:50+0100
                                                          Hmisc
2019-05-02 20:07:50+0100
                                                           ISLR
2019-05-02 20:07:50+0100
                                                       ISOcodes
2019-05-02 20:07:50+0100
                                                           ISWR
2019-05-02 20:07:50+0100
                                                           MASS
2019-05-02 20:07:50+0100
                                                          MBESS
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                     MLmetrics
                                                         Matrix
2019-05-02 20:07:50+0100
                                                MatrixModels
2019-05-02 20:07:50+0100
                                                       NbClust
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                      NlcOptim
                                                         OpenMx
                                                          PMCMR
2019-05-02 20:07:50+0100
                                      PerformanceAnalytics
2019-05-02 20:07:50+0100
                                                         R2admb
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                           RANN
                                                RColorBrewer
2019-05-02 20:07:50+0100
                                                         RCurl
2019-05-02 20:07:50+0100
                                                  RGtk2Extras
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                          ROCR
                                                        RSQLite
2019-05-02 20:07:50+0100
                                                         RWeka
2019-05-02 20:07:50+0100
                                                     RWekajars
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                         Rcpp
                                                     RcppEigen
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                  RgoogleMaps
Rserve
2019-05-02 20:07:50+0100
                                                         Rsolnp
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                        SQUAREM
                                                        SparseM
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                        TH.data
                                               TeachingDemos
                                                  VennDiagram
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                   WRTDStidal
                                                           XML
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                 adehabitatLT
2019-05-02 20:07:50+0100
                                                     animation
2019-05-02 20:07:50+0100
                                                      argparse
2019-05-02 20:07:50+0100
                                                     arulesViz
2019-05-02 20:07:50+0100
2019-05-02 20:07:50+0100
                                                       askpass
                                                   assertthat
 2019-05-02 20:07:50+0100
```

2. Question 2: To find the top most downloaded package.

```
(15 rows)
cqlsh:assignment 03> select * from question 02;
                         | package | count
2019-05-02 20:24:55+0100 |
                                igraph |
                                            48
2019-05-02 20:26:05+0100 |
                                Rcpp |
                                            16
2019-05-02 20:24:50+0100 | data.table |
                                            32
2019-05-02 20:25:55+0100 | dplyr |
                                            18
2019-05-02 20:25:20+0100 |
                                           19
                            magrittr |
                             tidyr |
tibble |
2019-05-02 20:26:00+0100 |
                                           15
2019-05-02 20:25:00+0100 |
                                            22
2019-05-02 20:25:35+0100 |
                                Rcpp |
                                           18
2019-05-02 20:25:15+0100 |
                                rlang |
2019-05-02 20:25:50+0100 |
                                rlang |
2019-05-02 20:25:25+0100 | pkgconfig |
                                            20
                            pillar |
tidyr |
2019-05-02 20:25:10+0100 |
                                            15
2019-05-02 20:26:10+0100 |
                                           19
2019-05-02 20:25:45+0100 |
                                           17
                                 DAAG |
2019-05-02 20:25:40+0100 |
                                 DAAG
                                            21
2019-05-02 20:25:05+0100 | data.table |
                                            30
2019-05-02 20:25:30+0100 | stringr |
                                            17
(17 rows)
cqlsh:assignment_03> select * from question_02;
time
                         | package | count
2019-05-02 20:24:55+0100 |
                                            48
                               igraph |
2019-05-02 20:26:05+0100 |
                                Rcpp |
                                            16
2019-05-02 20:24:50+0100 | data.table |
                                            32
2019-05-02 20:25:55+0100
                             dplyr |
                                            18
2019-05-02 20:25:20+0100 | magrittr |
                                            19
2019-05-02 20:26:00+0100 | tidyr |
                                           15
2019-05-02 20:25:00+0100 | tibble | 22
2019-05-02 20:25:35+0100 | Rcpp | 18
```

```
019-05-02 20:26:50+0100

019-05-02 20:26:05+0100

019-05-02 20:26:40+0100

019-05-02 20:26:20+0100

019-05-02 20:24:50+0100

019-05-02 20:26:45+0100

019-05-02 20:28:00+0100

019-05-02 20:27:25+0100

019-05-02 20:25:55+0100

019-05-02 20:25:55+0100
                                                                                                                                                                                                                                                                                                                                                                                                                                      Rcpp
rlang
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     16
35
18
32
32
22
48
18
                                                                                                                                                                                                                                                                                                                                                                      rlang
data.table
                                                                                                                                                                                                                                                                                                                                                                                                       cowplot
rlang
                                                                                                                                                                                                                                                                                                                                                                 assertthat |
dplyr |
gstat |
tibble |
        019-05-02 20:28:15+0100
019-05-02 20:27:45+0100
        019-05-02 20:28:05+0100
019-05-02 20:25:20+0100
                                                                                                                                                                                                                                                                                                                                                      htmlwidgets
magrittr
             019-05-02 20:28:35+0100
019-05-02 20:27:15+0100
                                                                                                                                                                                                                                                                                                                                                                                                                                   rlang
rlang
  2019-05-02 20:27:15+0100 2019-05-02 20:26:00+0100 2019-05-02 20:25:00+0100 2019-05-02 20:25:35+0100 2019-05-02 20:28:40+0100 2019-05-02 20:25:35+0100 2019-05-02 20:25:50+0100 2019-05-02 20:25:50+0100 2019-05-02 20:25:50+0100 2019-05-02 20:25:50+0100 2019-05-02 20:25:50+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 2019-05-02 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25+0100 20:25:25:25+0100 20:25:25:25*0100 20:25:25*0100 20:25:25*0100 20:25:25*0100 20:25:25*0100 20:25*0100 20:25*0100 20:25*0100 20:25*0100 20:25*0
                                                                                                                                                                                                                                                                                                                                                                                                                                        tidyr
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     15
45
22
18
29
31
27
19
55
18
20
64
25
18
17
31
                                                                                                                                                                                                                                                                                                                                                                                                                     rlang
tibble
                                                                                                                                                                                                                                                                                                                                                                                                                        Rcpp
tibble
                                                                                                                                                                                                                                                                                                                                                                                 RSQLite
htmltools
                                                                                                                                                                                                                                                                                                                                                                                                                                   rlang
utf8
                                                                                                                                                                                                                                                                                                                                                                                 rlang
pkgconfig
                                                                                                                                                                                                                                                                                                                                                                                                                  Rcpp |
purrr |
gsubfn |
XML |
        019-05-02 20:27:35+0100
019-05-02 20:27:55+0100
        019-05-02 20:27:05+0100
019-05-02 20:28:20+0100
2019-05-02 20:28:20+0100 | 2019-05-02 20:28:45+0100 | 2019-05-02 20:28:45+0100 | 2019-05-02 20:25:10+0100 | 2019-05-02 20:26:10+0100 | 2019-05-02 20:26:25+0100 | 2019-05-02 20:26:25+0100 | 2019-05-02 20:28:25+0100 | 2019-05-02 20:28:30+0100 | 2019-05-02 20:25:45+0100 | 2019-05-02 20:25:45+0100 | 2019-05-02 20:25:45+0100 | 2019-05-02 20:25:45+0100 | 2019-05-02 20:25:45+0100 | 2019-05-02 20:25:30+0100 | 2019-05-02 20:26:15+0100 | 2019-05-02 20:26:15+0100 | 2019-05-02 20:26:15+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0100 | 2019-05-02 20:26:55+0
                                                                                                                                                                                                                                                                                                                                                                                                             ggplot2
pillar
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     19
67
20
17
17
23
21
30
17
                                                                                                                                                                                                                                                                                                                                                                                                                                   dplyr |
rlang |
XML |
DAAG |
                                                                                                                                                                                                                                                                                                                                                                                                                                                         XML
                                                                                                                                                                                                                                                                                                                                                                   data.table stringr
                                                                                                                                                                                                                                                                                                                                                                                                             rlang
webshot
                                                                                                                                                                                                                                                                                                                                                                                                                        scales
Rcpp
yaml
  2019-05-02 20:27:00+0100
2019-05-02 20:26:35+0100
```

3. Question 3: To find the top 5 countries along with number of downloads.

cqlsh:assignment_03> select	* from qu	uestion_
time	country	count
		+
2019-05-02 20:37:35+0100		
2019-05-02 20:37:35+0100		116
2019-05-02 20:37:35+0100		
2019-05-02 20:37:35+0100		
2019-05-02 20:37:35+0100		
2019-05-02 20:37:30+0100		113
2019-05-02 20:37:30+0100		115
2019-05-02 20:37:30+0100		321
2019-05-02 20:37:30+0100		
2019-05-02 20:37:30+0100		
2019-05-02 20:37:45+0100		
2019-05-02 20:37:45+0100		
2019-05-02 20:37:45+0100		148
2019-05-02 20:37:45+0100		159
2019-05-02 20:37:45+0100		256
2019-05-02 20:37:15+0100	CA	132
2019-05-02 20:37:15+0100		114
2019-05-02 20:37:15+0100	US	342
2019-05-02 20:37:15+0100		94
2019-05-02 20:37:15+0100	IT	202
2019-05-02 20:37:20+0100	CA	127
2019-05-02 20:37:20+0100	CN	146
2019-05-02 20:37:20+0100	ES	116
2019-05-02 20:37:20+0100	US	378
2019-05-02 20:37:20+0100		129
2019-05-02 20:37:25+0100	CA	123
2019-05-02 20:37:25+0100		111
2019-05-02 20:37:25+0100	NA	111
2019-05-02 20:37:25+0100	US	287

2019-05-02 20:45:00+0100	NΔ	218	
2019-05-02 20:45:00+0100			
2019-05-02 20:37:30+0100		•	
2019-05-02 20:37:30+0100		•	
2019-05-02 20:37:30+0100		•	
2019-05-02 20:37:30+0100			
2019-05-02 20:37:30+0100			
2019-05-02 20:44:25+0100			
2019-05-02 20:44:25+0100			
2019-05-02 20:44:25+0100			
2019-05-02 20:44:25+0100			
2019-05-02 20:44:25+0100			
2019-05-02 20:44:35+0100	CA	96	
2019-05-02 20:44:35+0100	HK	87	
2019-05-02 20:44:35+0100	NA	116	
2019-05-02 20:44:35+0100	US	297	
2019-05-02 20:44:35+0100	US	372	
2019-05-02 20:45:50+0100	CA	117	
2019-05-02 20:45:50+0100	NA	171	
2019-05-02 20:45:50+0100	US	348	
2019-05-02 20:45:50+0100	FR	165	
2019-05-02 20:45:50+0100	US	233	
2019-05-02 20:44:40+0100	CA	101	
2019-05-02 20:44:40+0100	IN	112	
2019-05-02 20:44:40+0100	NA	91	
2019-05-02 20:44:40+0100	US	323	
2019-05-02 20:44:40+0100		493	
2019-05-02 20:47:00+0100		99	
2019-05-02 20:47:00+0100		131	
2019-05-02 20:47:00+0100		331	
2019-05-02 20:47:00+0100			
2019-05-02 20:47:00+0100			
2019-05-02 20:46:40+0100			
2019-05-02 20:46:40+0100		•	
2019-05-02 20:46:40+0100		•	
2019-05-02 20:46:40+0100		•	
2019-05-02 20:46:40+0100		•	
2019-05-02 20:45:20+0100			
2019-05-02 20:45:20+0100			
2019-05-02 20:45:20+0100	US		
2019-05-02 20:45:20+0100	FR		
2019-05-02 20:45:20+0100	US		
2019-05-02 20:43:50+0100	CA	92	
2019-05-02 20:43:50+0100	NA	88	
2019-05-02 20:43:50+0100	US	589	
2019-05-02 20:43:50+0100 2019-05-02 20:43:50+0100	NA	87	
2019-03-02 20:43:50+0100	US	546	
MORE			
HORE			

Question 4: To find number of downloads for ggplot2 package.

```
cqlsh:assignment 03> select * from question 04;
                                | package | count
2019-05-02 20:50:10+0100 | ggplot2 |
2019-05-02 20:50:00+0100 | ggplot2 |
                                 ggplot2
                                 ggplot2
2019-05-02 20:49:55+0100
2019-05-02 20:49:45+0100
                                 ggplot2
2019-05-02 20:49:50+0100 |
2019-05-02 20:49:40+0100 |
                                 ggplot2
                                 ggplot2
 2019-05-02 20:50:05+0100
                               | ggplot2
cqlsh:assignment 03> select * from question 04;
                               | package | count
2019-05-02 20:51:20+0100 | ggplot2 |
2019-05-02 20:50:20+0100 |
2019-05-02 20:50:15+0100 |
2019-05-02 20:51:05+0100 |
                                  ggplot2
                               | ggplot2
                                 ggplot2
 2019-05-02 20:50:10+0100
                                 ggplot2
 2019-05-02 20:51:10+0100
                                  ggplot2
2019-05-02 20:50:40+0100
2019-05-02 20:50:00+0100
                                 ggplot2
                                 ggplot2
 2019-05-02 20:50:45+0100
                                 ggplot2
2019-05-02 20:49:55+0100
                                 ggplot2
2019-05-02 20:51:50+0100
                                 ggplot2
2019-05-02 20:51:45+0100
2019-05-02 20:51:00+0100
2019-05-02 20:51:25+0100
2019-05-02 20:51:30+0100
                                  ggplot2
                                  ggplot2
                                  ggplot2
                                  ggplot2
 2019-05-02 20:49:45+0100
                                  ggplot2
 2019-05-02 20:50:55+0100
                                  ggplot2
 2019-05-02 20:51:35+0100
                                 ggplot2
 2019-05-02 20:51:15+0100
                                 ggplot2
2019-05-02 20:50:35+0100
                                 ggplot2
2019-05-02 20:51:55+0100 |
                                 ggplot2
2019-05-02 20:50:25+0100
                                 ggplot2
2019-05-02 20:49:50+0100
2019-05-02 20:50:30+0100
                                  ggplot2
                                  ggplot2
2019-05-02 20:49:40+0100
                                  ggplot2
 2019-05-02 20:50:05+0100 |
                                 ggplot2
 2019-05-02 20:50:50+0100
                                  ggplot2
 2019-05-02 20:51:40+0100 | ggplot2 |
(28 rows)
cqlsh:assignment 03>
```

time	package	count
2019-05-02 20:52:50+0100	ggplot2	т I 8
2019-05-02 20:51:20+0100	ggplot2	
2019-05-02 20:50:20+0100	ggplot2	
2019-05-02 20:50:15+0100		
2019-05-02 20:51:05+0100	ggplot2	
2019-05-02 20:50:10+0100	ggplot2	
2019-05-02 20:51:10+0100	ggplot2	
2019-05-02 20:50:40+0100	ggplot2	
2019-05-02 20:50:00+0100	ggplot2	
2019-05-02 20:50:45+0100	ggplot2	
2019-05-02 20:52:20+0100	ggplot2	
2019-05-02 20:52:35+0100		
2019-05-02 20:49:55+0100		
2019-05-02 20:51:50+0100	ggplot2	
2019-05-02 20:52:25+0100	ggplot2	
2019-05-02 20:52:00+0100	ggplot2	
2019-05-02 20:52:05+0100	ggplot2	
2019-05-02 20:51:45+0100	ggplot2	
2019-05-02 20:51:00+0100	ggplot2	
2019-05-02 20:51:25+0100	ggplot2	
2019-05-02 20:51:30+0100		
2019-05-02 20:52:15+0100		
2019-05-02 20:52:15+0100	ggplot2 ggplot2	
2019-05-02 20:49:45+0100	ggplot2	
2019-05-02 20:49:4570100	ggplot2	
2019-05-02 20:50:55+0100	ggplot2 ggplot2	
2019-05-02 20:50:53+0100	ggplot2 ggplot2	
2019-05-02 20:51:35+0100		
	ggplot2	
2019-05-02 20:51:15+0100	ggplot2	
2019-05-02 20:50:35+0100		
2019-05-02 20:52:30+0100		
2019-05-02 20:51:55+0100	ggplot2	
2019-05-02 20:52:10+0100	ggplot2	
2019-05-02 20:50:25+0100	ggplot2	
2019-05-02 20:49:50+0100	ggplot2	
2019-05-02 20:50:30+0100	ggplot2	
2019-05-02 20:52:55+0100	ggplot2	
2019-05-02 20:49:40+0100	. 332	
2019-05-02 20:50:05+0100		
2019-05-02 20:50:50+0100		
2019-05-02 20:51:40+0100	ggplot2	
2019-05-02 20:52:40+0100	ggplot2	
2019-05-02 20:52:45+0100	ggplot2	9
(43 rows)		